



引用格式: 苗鹏宇, 王自法, 位栋梁, 等. 基于机器学习方法的地震破坏预测[J]. 科学技术与工程, 2023, 23(14): 5903-5913.

Miao Pengyu, Wang Zifa, Wei Dongliang, et al. Earthquake damage prediction based on machine learning[J]. Science Technology and Engineering, 2023, 23(14): 5903-5913.

基于机器学习方法的地震破坏预测

苗鹏宇¹, 王自法^{2,3*}, 位栋梁³, 赵登科², 王祥祺¹

(1. 河南大学土木建筑学院, 开封 475004; 2. 中国地震局工程力学研究所, 哈尔滨 150080;

3. 中震科建(广东)防灾减灾研究院, 韶关 512026)

摘要 地震破坏预测研究对于建筑结构减灾规划、震前风险预测、震后应急评估有着重要意义。传统的方法因为受到震害资料数量的限制以及计算精度和能力的制约,一般基于经验只考虑少数因素对结构破坏的影响。通过使用随机森林算法,设计了一个综合考虑地震动、结构和场地等多维度信息的分类方法,用以预测建筑物的地震破坏程度。本文研究框架基于新西兰国家地震委员会所收集的 27 次地震详细破坏资料,处理得到 14.2 万条高质量建筑物损失数据,考虑了谱加速度、建筑形状、层数等 16 个影响因素,将 4 种不同的损伤状态作为模型的学习标签进行地震破坏预测训练。结果表明,随机森林算法在 6 种分类算法中性能最佳,经过学习曲线法调参、代价敏感学习之后,经过优化得到的随机森林模型对于测试集的整体预测精确率可以达到 75.4%,对 4 种损伤标签的召回率分别达到了 88.2%、55.0%、60.7% 和 70.8%,远好于其他方法。当只考虑对结果影响最重要的前 12 个因素,该模型的预测精度仍然能够达到 73.7%。可见,基于此框架所训练的预测模型具有良好的精度与适用性,同时该框架对于中国震害资料大数据库的研究具有较高的参考价值。

关键词 地震破坏预测; 破坏状态预测; 机器学习; 随机森林算法; 新西兰地震损失数据

中图分类号 P315.9;

文献标志码 A

Earthquake Damage Prediction Based on Machine Learning

MIAO Peng-yu¹, WANG Zi-fa^{2,3*}, WEI Dong-liang³, ZHAO Deng-ke², WANG Xiang-qi¹

(1. School of Civil Engineering and Architecture, Henan University, Kaifeng 475004, China;

2. Institute of Engineering Mechanics, China Earthquake Administration, Harbin 150080, China;

3. CEAKJ ADPRHexa Inc., Shaoguan 512026, China)

[Abstract] Seismic damage prediction studies are of great importance for disaster mitigation planning, pre-earthquake risk prediction, and post-earthquake emergency assessment. Traditional methods usually consider the impacts by a limited number of influencing factors based on empirical experience due to the constraint of limited detailed damage data and computing resources. Based on the random forest algorithm, a classification model that integrates multidimensional information including ground shaking, structural information, and site conditions was designed to predict structural earthquake damage. Based on the detailed damage information of 27 earthquakes assembled by the Earthquake Commission of New Zealand, 142 000 high-quality post-processed building damage records were used for training the prediction model, which included 16 influencing factors such as spectral acceleration, building shape, and number of stories. Four damage state were used as learning labels of the model. The results show that the random forest algorithm has the best performance among six classification models used in the comparison study. After fine tuning the learning curve parameters and cost-sensitive learning, the overall prediction accuracy of the optimal random forest model can reach 75.4% in the test set, and the recall rates for the four damage labels reach 88.2%, 55.0%, 60.7% and 70.8%, respectively, demonstrating the efficacy of the proposed approach based on the large detailed damage data sets. When the first 12 factors are used based on their contribution to model accuracy, the overall classification accuracy of the model can still reach 73.7%. It can be seen that the prediction model trained based on this research framework has good accuracy and applicability, and the framework has a high reference value for future research on the domestic earthquake damage.

[Keywords] earthquake damage prediction; damage state prediction; machine learning; random forest algorithm; New Zealand earthquake loss data

收稿日期: 2022-09-25; 修订日期: 2023-03-09

基金项目: 国家自然科学基金面上项目(51978634); 中国地震局工程力学研究所基本科研业务费专项(2021B09)

第一作者: 苗鹏宇(1998—)男,汉族,河南新乡人,硕士研究生。研究方向:地震易损性。E-mail: mpy_dy1010@163.com。

* 通信作者: 王自法(1965—)男,汉族,安徽合肥人,博士,研究员。研究方向:巨灾风险。E-mail: zifa@iem.ac.cn。

投稿网址: www.stae.com.cn

地震破坏预测,一般被笼统地称之为震害预测,是指地震对工程结构可能造成的破坏程度的估计,它对于建筑结构抗震设计、减灾规划、震前风险预测、震后应急评估等有着重要意义^[1-3]。

传统的建筑物震害预测方法从研究对象的角度的度一般可以分为单体震害预测和群体震害预测。目前常见的单体震害预测方法有历史震害统计法、专家评估法、模糊类比法、半经验半理论法、结构理论计算方法和动态分析法等^[4]。建筑物群体的震害预测是由每一个建筑物单体的震害预测结果集成的,一般通过已有单体样本结构构造与拟预测区域的结构构造的相似性来模拟预测区的震害矩阵^[5]。由于城市发展日新月异以及各类新旧建筑物按照不同抗震规范设计建设,只考虑有限个影响因素组合的震害矩阵预测方法存在着很大的应用制约^[6]。因此,迫切需要寻找一种可以考虑更多影响因素的高效可靠方法进行建筑物群体震害预测。

随着当代计算机应用技术的进步以及建筑物损坏数据的积累,中外学者利用各种机器学习(machine learning, ML)方法对结构的震害损失预测进行了有益的尝试。金赟赟等^[7]提出采用分类贝叶斯网络模型对1350栋砌体建筑进行群体震害预测,其研究结果表明ML方法可以实现区域或城市整体快速震害预测。张令心等^[8]利用40栋框架结构的数据样本,基于列文伯格-马夸尔特(Levenberg-Marquardt, LM)算法的反向传播(back propagation, BP)神经网络设计了一个具有较高的普适性的震害预测模型,并建议增加影响因子的种类与样本数量以增加模型精度;Roeslin等^[9]讨论了随机森林等4种分类算法,并表明在2017年墨西哥普埃布拉地震中237座受损建筑物数据集上,随机森林表现最好且达到了65%以上的预测精度,并建议使用更大的数据集以提高模型精度。Stojadinovi等^[10]基于2010年克拉列沃(Kraljevo)地震受损1979座受损建筑设计了一种地震损失快速评估框架,虽然随机森林模型整体预测精度高达85%,但是其模型对于倒塌建筑的识别准确率仅有30%。Mangalathu等^[11]基于2014年南纳帕(South Napa)地震中2274组受损房屋数据,训练得到了准确率高达66%的随机森林分类模型,同时强调了数据量与数据维度的必要性。虽然以上研究均展现出了ML模型在建筑物震害损失预测方面的优势,但仍然存在以下限制:①由于实际震害损伤调查数据较少,故当前大多数研究所用的数据来自建模分析方法,该方法的优点是较为准确地量化建筑损伤程度并且被大多数研究人员所接受,但是有研究^[9-10, 12-16]认为,

这种方法所得数据难以模拟出建筑实际震害过程中的不确定性,而实际调查的地震破坏资料更能代表建筑的实际反应;②现有实际震害研究数据往往来自单次地震事件,所以研究结果缺乏足够的地震事件泛化能力;③因为一次地震的影响尺度通常为城市级别,只能代表较小的地区,所以研究结果缺乏足够的区域泛化能力;④类似研究所采用的数据数量不足,考虑的影响因素不多,所以研究结果的精度有限,无法充分挖掘各种影响因素与建筑物地震破坏之间的潜在关系。

为了解决上述问题,现使用新西兰1997—2014年间27次地震事件在新西兰全国范围内收集整理的142543条详细震害数据资料作为样本数据训练模型,将谱加速度(spectral acceleration, S_a)、液化记录、层数等16个影响因素作为ML模型的输入变量,设计一个综合考虑地震动参数、结构参数、场地参数等多维度信息的震害预测模型。

1 数据

1.1 数据集介绍

新西兰位于向西移动的太平洋板块与向北移动的澳大利亚板块边缘,两个主要构造板块相互推挤导致了新西兰地震活动性较高^[17]。新西兰政府所成立地震委员会(Earthquake Commission, EQC)在几十年间的运行中,积累了大量翔实的房屋索赔资料,形成了一个包含建筑原始信息、震后详细损伤信息等在内的庞大数据库。

通过对源数据库进行质量控制筛选,最终选取信息比较全面的1997—2014年间27次主要地震,其中包含了新西兰历史上几次重大地震事件,如2010—2011年坎特伯雷地震序列。此外,27次地震事件和新西兰建筑物位置的空间分布如图1所示,其中27次地震的基本信息如表1所示。由此可见,所选择的数据分布于新西兰全国各地,充分考虑了发生于不同空间位置的多次地震事件对于大量建筑结构的地震破坏影响。

1.2 地震动参数计算

建筑物地震破坏研究需要选定有效的地震动强度指标(intensity measure, IM)。传统的建筑物地震破坏研究常常将地震烈度或者地面峰值加速度(peak ground acceleration, PGA)作为描述地震的参数,它们的获取方式虽然便捷直观,但是由于没有包含地震动中的频谱信息从而无法很好地表现建筑物和地震动的频谱特征,而采用与建筑自振周期相对应的谱加速度能够很好地保留地震动频率信息^[18-20],故选用 S_a 作为样本数据中的IM。

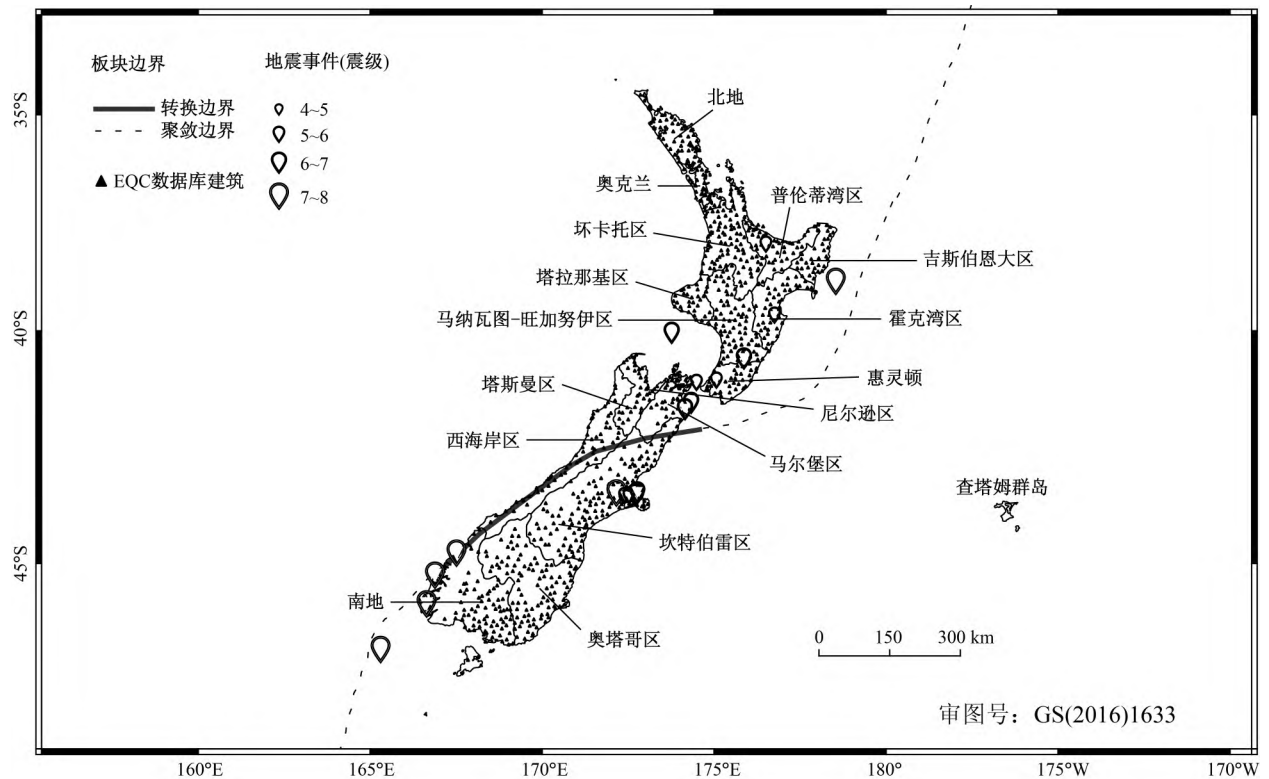


图1 新西兰建筑物及地震事件分布图

Fig. 1 New Zealand building and earthquake event distribution map

表1 27次地震基本信息

Table 1 Basic information of 27 earthquakes

事件时间	震级 / Mw	震源位置	震源深度 / km	地震构造分类	断层类型
1997-06-20	5.4	41.15°S 174.49°E	37	潜没板块地震	正断层
2003-08-21	7.1	45.19°S 166.83°E	24	俯冲带板缘地震	逆断层
2004-07-18	5.4	38.01°S 176.51°E	5	浅地壳地震	走滑断层
2004-11-22	7.0	46.6°S 165.32°E	12	俯冲带板缘地震	逆断层
2005-01-20	5.3	41.09°S 175.05°E	31	潜没板块地震	正断层
2007-10-15	6.7	44.74°S 167.44°E	5	俯冲带板缘地震	斜向滑坡断层
2007-12-20	6.7	38.89°S 178.54°E	33	潜没板块地震	正断层
2008-08-25	5.5	39.72°S 176.85°E	32	潜没板块地震	正断层
2009-07-15	7.8	45.77°S 166.59°E	12	俯冲带板缘地震	逆断层
2010-09-04	7.2	43.53°S 172.17°E	11	浅地壳地震	走滑断层
2010-10-18	4.8	43.59°S 172.56°E	5	浅地壳地震	走滑断层
2010-11-14	4.4	43.58°S 172.42°E	11	浅地壳地震	走滑断层
2010-12-25	4.8	36.82°S 177.12°E	232	浅地壳地震	走滑断层
2011-01-18	5.0	38.11°S 176.18°E	151	浅地壳地震	走滑断层
2011-02-04	4.3	43.63°S 172.35°E	5	浅地壳地震	走滑断层
2011-02-21	6.2	43.58°S 172.68°E	5	浅地壳地震	斜向滑坡断层
2011-04-16	5.0	43.60°S 172.52°E	9	浅地壳地震	走滑断层
2011-05-09	4.9	43.57°S 172.84°E	12	浅地壳地震	走滑断层
2011-06-05	5.1	43.59°S 172.39°E	9	浅地壳地震	走滑断层
2011-06-13	6.0	43.58°S 172.74°E	7	浅地壳地震	斜向滑坡断层
2011-06-21	5.2	43.40°S 172.52°E	9	浅地壳地震	走滑断层
2011-10-09	4.9	43.57°S 172.84°E	8	浅地壳地震	逆断层
2011-12-23	5.9	43.52°S 172.75°E	7	浅地壳地震	斜向滑坡断层
2012-07-03	6.2	40.05°S 173.76°E	241	潜没板块地震	未知断层
2013-07-21	6.5	41.60°S 174.32°E	16	浅地壳地震	走滑断层
2013-08-16	6.6	41.73°S 174.15°E	8	浅地壳地震	走滑断层
2014-01-20	6.3	40.62°S 175.87°E	34	潜没板块地震	正断层

由于新西兰和日本均位于太平洋板块的边缘,二者均是狭长的岛国,因此采用基于日本观测数据的地震动衰减模型来预测新西兰的地震动参数是比较好的选择。本文研究采用 Zhao 等^[21-23]所提出的地震动预测方程(ground motion prediction equation, GMPE)计算建筑物处的 S_a ,其中地下 30 m 深度的平均剪切波速度(average shear wave velocities in the first 30 m depth, V_{s30})参考 Wald 等^[24]的思路,利用地形坡度匹配法获得各个建筑物所在地信息。本课题组^[25]的研究成果已经验证了该模型于新西兰地区的有效性。

1.3 地震损伤标记

由于本文研究所采用的新西兰详细地震破坏资料包含着具体的损失信息,为了便于与以前的相关研究进行对比,参考相关的研究^[26-28]所采用的分类方法,利用经济损失比对建筑结构的损伤程度进行标记。具体损伤程度的分类参考美国应用技术协会所发布地震震害评估标准 ATC-13^[29],确定建筑物的 4 种损伤状态如表 2 所示。当 $0 < \text{建筑损失比}(\text{damage ratio}, Dr) \leq 10\%$ 时,即判定该建筑发生轻微破坏,不修补或轻微修补即可立即使用;当 $10\% < Dr \leq 30\%$ 时,判定该建筑发生中等破坏,经过适当修缮后可以继续使用;当 $30\% < Dr \leq 60\%$ 时,判定该建筑发生严重破坏,通过大面积修缮后鉴定合格仍可继续使用;当 $Dr > 60\%$ 时,判定该建筑发生毁坏,修复成本过高或已无修复价值。

表 2 受损建筑损伤标签划分
Table 2 Damage label division of damaged buildings

标签	损伤状态	Dr 损伤范围
0	轻微破坏	$0 < Dr \leq 10\%$
1	中等破坏	$10\% < Dr \leq 30\%$
2	严重破坏	$30\% < Dr \leq 60\%$
3	毁坏	$60\% < Dr \leq 100\%$

1.4 模型特征参数选择

模型特征是指训练机器学习模型所用数据的维度。科学且全面地选择模型特征是保证模型精度的必要条件,因此,在确定输入模型特征时,既要考虑影响建筑物地震损失的结构因素,也要尽可能考虑到建筑之外场地环境因素。依据上述考虑,基于本数据库已有信息以及研究目标,最终选取了以下特征作为震害损伤因子进行后续研究。

(1) 地震相关信息:由于结构地震响应是一个极为复杂的多因素作用过程,同时考虑到机器学习技术对于输入和输出之间复杂映射关系的超强学

习能力,本研究将谱加速度 S_a 、震中距、震级和震源深度作为地震相关信息特征。

(2) 建筑物相关信息:由于建筑造价直接影响到建造成本,而成本是影响建筑质量(即所用的材料和施工中的工艺质量)的关键因素,考虑到不同面积的建筑物总造价不尽相同,本文研究取各个建筑物的单位面积价值(即建造造价/建筑物总面积的比值)以反映建筑物质量情况;其次,由于建筑物材料的老化程度以及抗震设防标准在更新迭代,本文研究将建造年代作为反映房屋的抗震能力的差异性的因素;再次,由于本数据库调查时并未将结构类型作为灾害调查要求,故根据墙体材料类别作为判断结构类型的直接参数;此外,层数、建筑用途、建筑形状等传统因素也共同被作为影响因素;最后,依据联邦应急管理署(Federal Emergency Management Agency, FEMA)所颁布的 FEMA 356^[30]规范来看,建筑物地震破坏中非结构构件的破坏往往占据相当程度的比例,故本文研究额外将屋顶材料、楼板材料等作为影响建筑物地震破坏的影响因素加以考虑。

(3) 场地相关信息:历次地震资料^[31-33]表明液化现象显著影响着建筑物的破坏程度,最近刘渊等^[17]研究再次验证了地震液化会加重建筑物的震害损失,尤其会加重结构构件的破坏程度。现有传统的地震破坏预测研究因为缺少场地是否液化以及液化造成破坏的数据而经常忽略了这个影响因素,本文研究依靠数据优势将场地液化情况作为预测建筑物不同程度损伤的因素加以考虑。此外,将 V_{s30} 作为影响因素,目的是为了研究不同场地类型对于建筑结构破坏的影响。

最终确定 16 个震害损失因子作为模型的输入特征,各个特征描述、计算方式及数据来源如表 3 所示。

1.5 训练前数据预处理

上述步骤完成后形成了初始数据库,但该数据库并不能直接用于震害预测模型的输入,训练前仍需要进行以下预处理。

(1) 由于模型算法的本质是数值运算,因此模型无法识别非数字信息。利用 Scikit-learn 库提供的 LabelEncoder 编码工具,将字符串转换为整数或浮点值,实现文本数值化。

(2) 需要对非连续的离散型数据进行处理,如受损房屋的建造年代等,虽然它们具备数值属性,但是对于模型学习过程这些数值没有意义,因此同样需要编码工具,使其转化为虚拟数据,成为能表达现实含义的有效信息。

表 3 模型参数汇总
Table 3 Selected model parameters

编号	特征类别	特征	特征描述	计算方式/来源
1	地震信息	Sa	目标建筑物的谱加速度	GMPE
2		震中距	目标建筑物与震中距离	Haversine 公式
3		震级	地震事件强度	GeoNet 地震目录
4		震源深度	地震事件震源深度	
5	建筑物信息	单位面积价值	建筑物的建造造价与建筑物总面积的比值	EQC 数据库
6		* 建造年代	根据抗震规范年份分为 4 类: ① < 1935; ② 1935—1965; ③ 1965—1980; ④ 1980—1992; ⑤ 1992—2004; ⑥ > 2004	
7		层数	建筑物的层数	
8		* 屋顶材料	屋顶覆盖层材料类型: ① 铁; ② 瓷砖; ③ 纤维类; ④ 毡类; ⑤ 铝; ⑥ 石材; ⑦ 混凝土; ⑧ 灰泥; ⑨ 木材; ⑩ 塑料; ⑪ 玻璃; ⑫ 砖; ⑬ 混合材料	
9		* 楼板材料	楼板覆盖层材料类型: ① 混凝土; ② 木材; ③ 复合材料	
10		* 基础材料	基础材料类型: ① 混凝土; ② 木; ③ 砖	
11		* 墙体材料	墙体框架材料类型: ① 混凝土; ② 木材; ③ 砖; ④ 铁; ⑤ 石材	
12		* 车库情况	建筑物是否具有内部车库: ① 有; ② 无	
13		* 建筑用途	建筑物的使用用途: ① 商业用地; ② 园艺用地; ③ 工业用地; ④ 生活用地; ⑤ 政府用地; ⑥ 大型公寓用地; ⑦ 农畜用地; ⑧ 公共事业用地; ⑨ 其他用地	
14		* 建筑形状	建筑物的平面形状: ① 矩形; ② T 型; ③ L 型; ④ 其他形状	
15	场地信息	* 液化情况	建筑物所在地是否产生液化现象: ① 有; ② 无	USGS
16		Vs30	地表下 30 m 土体平均剪切波速	

注: 无“*”表示连续型变量; 有“*”表示离散型变量。

(3) 尽管 EQC 数据库是由官方收集, 仍存在部分记录信息不完整的情况。本文研究出于以下两方面考虑对有缺失信息的数据进行处理: 一方面, 目前大多数机器学习模型不支持对缺失值的处理^[34]; 另一方面, 即使个别模型支持处理缺失值, 如 XGboost、LightGBM 等, 但是在实际训练过程中也会因为将稀疏矩阵作为输入数据而降低模型统计学习能力, 导致模型鲁棒性较差。因此, 为保证所用数据和结果的完整性, 本文研究仅选择信息完全的数据记录。

(4) 采用机器学习领域最典型的“八二原则”对样本数据进行划分, 即从地震损伤样本数据库中随机地抽取 80% 数据(114 034 条) 作为训练集, 剩余 20% 数据(28 509 条) 作为测试集。其中训练集、测试集中各类别数据分布情况如表 4 所示。

表 4 预处理后训练集、测试集数据分布
Table 4 Data distribution of training set and test set after preprocessing

样本数据	类别	描述	数量	占比/%
训练集(80%)	0	轻微破坏	61 271	53. 7
	1	中等破坏	26 748	23. 5
	2	严重破坏	13 035	11. 4
	3	毁坏	12 980	11. 4
测试集(20%)	0	轻微破坏	15 429	54. 1
	1	中等破坏	6 654	23. 3
	2	严重破坏	3 227	11. 3
	3	毁坏	3 199	11. 3

2 数据

2.1 模型比较及选用

目前在地震破坏预测研究中经常用到的机器学习方法有逻辑回归(logistic regression ,LR)^[35]、决策树(decision tree ,DT)^[11]、朴素贝叶斯(naive Bayes ,NB)^[36]、随机森林(random forest ,RF)^[37]、卷积神经网络(convolutional neural networks ,CNN)^[38]、线性判别分析(linear discriminant analysis ,LDA)^[36]等。由于每种机器学习算法各有千秋, 通常需要根据采用的数据和分析目标等特点选用合适的算法。考虑到本文研究所采用的数据量巨大且维度较多, 首先排除了训练效率低以及占用内存很高的算法, 如支持向量机(support vector machine ,SVM), 然后选用上述 6 种常见分类模型机器学习方法, 把它们同时应用于本文研究所采用的数据集上(各个模型的超参数均选择默认值), 最终通过分析比较各个模型的评价指标以确定最佳模型。现行评价分类模型的指标参数比较多, 主要有精确率(precision)、召回率(recall)、F₁ 测试值(F₁-score) 和准确率(accuracy)^[39]。由于 4 种标签数据并非均匀分布, 对上述 4 种指标采用加权(即在原有计算基础之上考虑不同类别样本占据总样本的权重) 的方式计算最终结果。4 个评测指标数值越接近 1, 说明模型分类性能越好, 越适用于本文研究数据。

6 种模型的性能对比结果如表 5 所示,其中随机森林算法在本文研究所采用的数据及特征参数中表现最佳,被选择为最终进行分析的方法。为了得到更好的预测结果,需要对随机森林算法中的超参数进行优化(调参)以提高模型的性能。

表 5 6 种机器学习分类模型性能对比
Table 5 Performance comparison of six machine learning classification models

算法名称	加权平均 精确率/%	加权平均 召回率/%	加权平均 F_1 -score	准确率/ %
LR	52.6	59.3	0.527	59.3
DT	69.1	68.8	0.690	68.8
NB	54.7	52.0	0.528	52.0
LDA	53.6	59.1	0.522	59.1
CNN	57.0	61.2	0.578	62.1
RF	71.2	72.4	0.715	72.4

2.2 模型训练及参数优化

现通过调用 sklearn 库搭建随机森林模型,并利用 1.4 节所确定的 16 个因素作为输入变量训练模型。模型的训练过程涉及几个重要的模型超参数:基学习器个数 (n_estimators)、决策树最大深度 (max_depth)、叶子节点最少样本数 (min_samples_leaf)、节点划分最小样本数 (min_samples_split) 和最大特征数 (max_features)。利用学习曲线法搜索最优的参数组合,并使用袋外得分 (out of bag score) 作为模型性能评估标准,其中袋外得分越接近 1,则

表示该模型分类精度越高。

学习曲线法的调参顺序是按照参数对于模型的影响程度依次进行的,具体步骤如下:首先,将基学习器个数取值区间设置为 1~500,设置步长为 1,其对应的学习曲线如图 2(a) 所示,可以发现袋外得分和基学习器个数接近对数型分布。当基学习器个数小于 100 时,袋外得分曲线表现为陡然上升趋势;当基学习器个数大于 100 时,袋外得分曲线发展平缓稳定。通过搜索该曲线的袋外得分最大值可知极值为 0.744,其对应的基学习器个数为 496。在基学习器个数为 496 的基础上,再次调整决策树最大深度参数。将决策树最大深度取值区间设置为 1~50,设置步长为 1,其对应的学习曲线如图 2(b) 所示。不难看出,当决策树最大深度大于 30 时,袋外得分基本稳定。当决策树最大深度为 32 时,袋外得分最高。同理,叶子节点最少样本数、节点划分最小样本数和最大特征数的学习曲线如图 2(c)~图 2(e) 所示,分别搜索各学习曲线上最高得分所对应的参数值,最终模型超参数如表 6 所示。

表 6 优化处理后的模型超参数列表
Table 6 Selected hyperparameters after optimization

参数名称	最优值	袋外得分
基学习器个数	496	0.781
决策树最大深度	32	
叶子节点最少样本数	1	
节点划分最小样本数	2	
最大特征数	15	

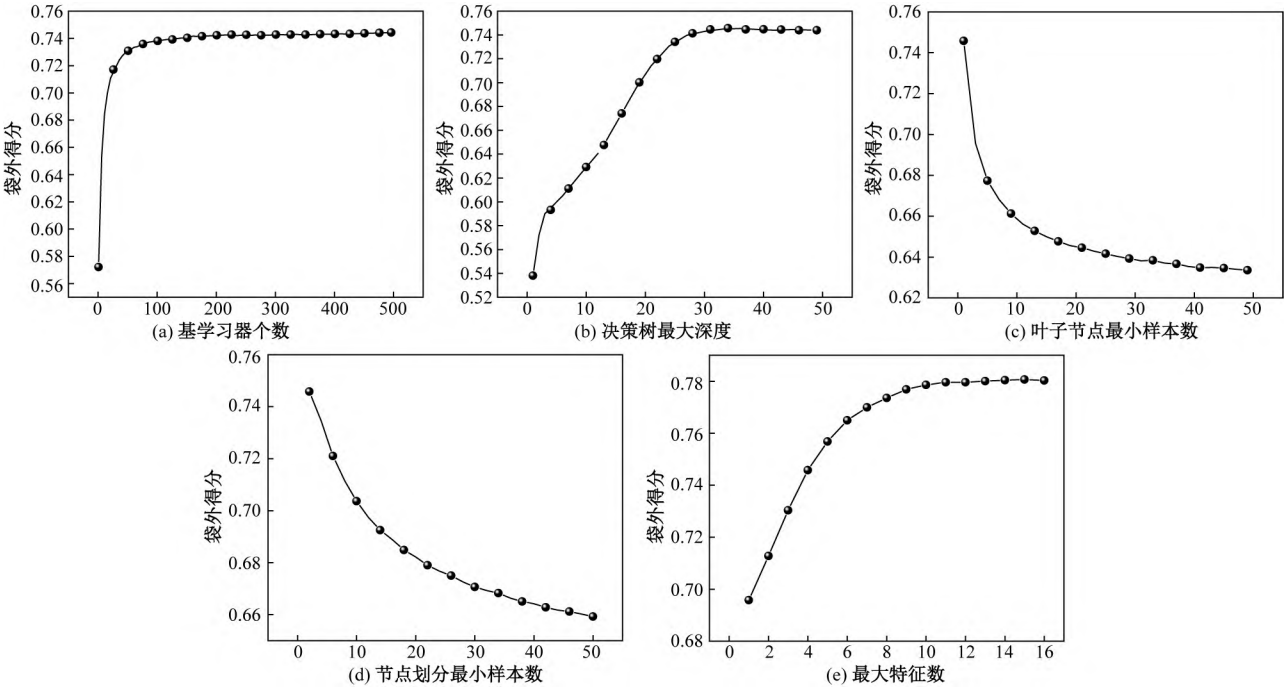


图 2 随机森林超参数学习曲线图
Fig. 2 Hyperparametric learning curve of random forest

3 结果与分析

3.1 混淆矩阵

采用2.2节选定的模型超参数,利用表4中的训练集(80%)训练随机森林模型,用测试集(20%)测试所选模型分类性能。为了直观展示随机森林模型在4个破坏标签上的分类表现,一般采用混淆矩阵(confusion matrix)来评估其分类性能^[40]。混淆矩阵中对角上的元素表示机器学习算法正确分类的样本数目,非对角线上元素表示错误分类的标签数目,样本数量下方的括号内数值表示该样本数量占测试集数量的百分比。第5行和第5列分别表示模型对于4类损伤标签数据的精准率和召回率结果。模型右下角为模型总体准确率,值越高(最高为100%),说明机器学习模型预测性能越强。最终随机森林模型在测试集上的混淆矩阵如图3所示。

		预测值				召回率
		0	1	2	3	
实际值	0	13 767 (48.3 %)	1 189 (4.2%)	229 (0.8%)	244 (0.9%)	89.2%
	1	2 383 (8.3%)	3 599 (12.6%)	349 (1.2%)	323 (1.1%)	54.1%
	2	458 (1.6%)	477 (1.7%)	1 886 (6.6%)	406 (1.4%)	58.4%
	3	377 (1.3%)	272 (1.0%)	320 (1.1%)	2 230 (7.8%)	69.7%
精确率		81.1%	65.0%	67.7%	69.6%	75.3%

(a) 随机森林

		预测值				召回率
		0	1	2	3	
实际值	0	13 613 (47.7 %)	1 286 (4.5%)	266 (0.9%)	264 (0.9%)	88.2%
	1	2 270 (8.0%)	3 662 (12.8%)	377 (1.3%)	345 (1.2%)	55.0%
	2	415 (1.5%)	444 (1.6%)	1 957 (6.9%)	411 (1.4%)	60.7%
	3	348 (1.2%)	271 (1.0%)	317 (1.1%)	2 263 (7.9%)	70.8%
精确率		81.8%	64.7%	67.1%	68.9%	75.4%

(b) 随机森林(代价敏感学习)

图3 随机森林模型混淆矩阵

Fig. 3 Confusion matrix of random forest model

由图3(a)可知,随机森林模型对于第0类标签,正确预测了15 429样本中的13 767个,召回率为89.2%;对于第1类标签,正确预测了6 654样本中的3 599个,召回率为54.1%;对于第2类标签,正确预测了3 227样本中的1 886个,召回率为58.4%;对于第3类标签,正确预测了3 199样本中的2 230个,召回率为69.7%。从精确率(第5行)来看,被该模型预测为第0类标签的数据中,实际为0类的数据为13 767个,精确率为81.1%。同样的,其他3类标签的预测精确率分别为65.0%、67.7%、69.6%。该模型整体准确率表现为75.3%。由此可见,经过调参后的随机森林模型能够以很高的准确率完成4种损伤标签的预测。

此外,由于一般地震发生后,灾区中发生轻微损伤建筑往往多于发生严重破坏的建筑(表4),这导致现有实际震害资料中数据存在不平衡性。本文研究采用代价敏感学习方法(cost-sensitive learning)来调整算法,以改善标签数量不平衡现象给模型所造成的性能下降问题。具体做法为,在最佳随机森林基础之上,通过调用随机森林中的Class_weight参数并重新训练模型,得到测试集的混淆矩阵结果如图3(b)所示。将图3(a)与图3(b)进行对比可知,虽然模型对于第0类召回率降低1.0%,但是对于第1、2、3类标签的召回率均有所提升,分别提升0.9%、2.3%和1.1%。模型整体准确率提高0.1%。

3.2 模型适用性的初步研究

为了提高上述模型应用于结构地震破坏预测的适用性,现提出一种迭代研究思路:首先在上述最佳模型基础之上得到各个特征因素对于模型预测精度的影响,然后根据影响程度从大到小有依据性地减少模型预测时所需因素的数量,从而达到以少量的数据特征维度对结构地震破坏进行预测的目的,旨在牺牲较小的预测精度换取模型更好的适用性。

首先,本文研究采用置换的思想得到各个特征对于模型精度的影响程度。此方法的主要思路是在模型训练完毕后,将测试集的某一特征列的数据顺序打乱,重新测试模型的性能并统计打乱前后模型的袋外得分变化,袋外得分变化越大则说明该特征对于模型的影响程度越大。16个特征对于模型精度的影响程度如图4所示。由图4可知,特征Sa数据顺序被打乱后导致模型的袋外得分变化最大(1.298),说明该特征是影响模型性能的最关键参数。从排序来看,各个特征对于模型的影响程度也各不相同,从变化幅度上大致上可以初步将Sa、液化情况、单位面积价值、震中距、建造年代、 V_{s30} 视为




图4 各特征对于随机森林模型袋外得分的影响

Fig. 4 The effect of each feature on the out-of-bag score of the random forest model

影响模型精度性能的关键参数: 将震级、层数、屋顶材料、建筑形状、震源深度、楼板材料视为影响模型精度性能的主要参数; 将建筑用途、墙体材料、基础材料、车库情况视为影响模型精度性能的次要参数。因此, 分别以图4前12个特征和前6个特征分别作为模型预测时所考虑的特征维度, 再次使用相同的测试集(表4)得到两模型的混淆矩阵(图5)。通过比较图3(b)和图5(a)可知, 当模型仅考虑排名前12个因素时, 模型一对于第0、1、2、3类标签的召回率分别降低了1.0%、2.7%、2.2%和2.3%, 模型整体准确率降低1.7%; 通过比较图3(b)和图5(b)可知, 当模型仅考虑排名前6个因素时, 模型二整体性能大幅度降低, 虽然模型对于第0类标签的召回率提高了2.4%, 但是模型对于第1、2、3类标签的召回率分别降低了29.9%、31.2%和20.4%, 模型整体准确率降低11.7%。可见, 经过迭代训练后的两模型整体性能均有所降低, 其中模型二的分类性能降低幅度最大, 原因是因为模型二忽略了部分对于模型精度产生影响的主要参数。这也说明了在本研究中综合考虑多维度信息的思路有利于提高模型的精度, 为保证预测的精度, 至少需要包括图4中的关键参数和主要参数。

最后, 为了证明本文研究提出模型方法的优越性, 将本文的结果和其他类似研究的结果进行了比较。目前类似研究的数据类型从获取方式上可以大致分为3类: 数值模拟数据、实地调查数据及遥感数据^[41]。相较而言, 目前遥感数据的可靠性有待进一步提升, 本文不作讨论; 不可否认的是, 数值模拟数据存在着一定优势, 近来基于此类模拟数据所训练的机器学习模型的预测精度^[42-45]甚至略高于本文。但是真实的建筑群是多样化的, 其真实的结构反应往往与理论模拟存在一定差距, 该类研究的意

		预测值				召回率
		0	1	2	3	
实际值	0	13 458 (47.2%)	1 283 (4.5%)	346 (1.2%)	342 (1.2%)	87.2%
	1	2 293 (8.0%)	3 481 (12.2%)	398 (1.4%)	482 (1.7%)	52.3%
	2	425 (1.5%)	407 (1.4%)	1 888 (6.6%)	507 (1.8%)	58.5%
	3	344 (1.2%)	281 (1.0%)	383 (1.3%)	2 191 (7.7%)	68.5%
精确率		81.5%	63.8%	62.6%	62.2%	73.7%

(a) 迭代后模型一(前12个特征)

		预测值				召回率
		0	1	2	3	
实际值	0	13 926 (48.8%)	804 (2.8%)	252 (0.9%)	447 (1.6%)	90.6%
	1	4 142 (14.5%)	1 661 (5.8%)	265 (0.9%)	586 (2.1%)	25.1%
	2	946 (3.3%)	535 (1.9%)	975 (3.4%)	771 (2.7%)	29.5%
	3	707 (2.5%)	459 (1.6%)	439 (1.5%)	1 594 (5.6%)	50.4%
精确率		70.8%	48.1%	51.0%	47.4%	63.7%

(b) 迭代后模型二(前6个特征)

图5 迭代后随机森林模型的混淆矩阵

Fig. 5 Confusion matrix for random forest model after iteration

义之一在于利用高质量数据探索机器学习方法进行震害预测的“上限”; 与之相反, 利用实地调查数据的研究意义之一在于考虑建筑结构的真实反应, 表7主要列举了基于实地调查数据进行震害预测(机器学习方法)的相关研究。可以看出本文研究内容在时间尺度、空间尺度、数据量尺度、特征数量维度数、以及模型预测精度方面, 相较于现有同类研究有了明显改善。

4 结论

基于新西兰1997—2014年间所发生的27次实际地震破坏资料, 本文研究提出一种震害大数据研究框架并设计了一个综合考虑地震动、结构和场地等多维度信息的震害预测方法, 得出如下结论。

表 7 本文研究内容与现有研究内容对比
Table 7 Comparison of this study with existing studies

文献	最佳模型	特征数量	任务类型	研究数据	最高精度 /%
[36]	随机森林 多层感知机	6	五分类	1999 年迪兹杰(Duzce) 地震中受损的 484 栋钢筋混凝土建筑	45. 7
			二分类		77. 5
[9]	随机森林	12	二分类	2017 年普埃布拉-莫雷洛斯(Puebla-Morelos) 地震 237 座受损建筑物	67. 0
[11]	随机森林	8	三分类	2014 年纳帕(South Napa) 地震中 2276 栋受损建筑	66. 0
[46]	多层感知器	6	五分类	1999 年迪兹杰(Duzce) 地震中 484 栋受损钢筋混凝土建筑	52. 0
[47]	支持向量机	22	五分类	1999 年迪兹杰(Duzce) 地震中 484 栋受损钢筋混凝土建筑	52. 0
			三分类	2016 年厄瓜多尔(Ecuador) 地震中 171 栋受损建筑	60
			三分类	2010 年海地(Haiti) 地震中 142 栋受损建筑	68
			四分类	2015 年尼泊尔(Nepal) 地震中 135 栋受损建筑	67
			四分类	2017 年韩国(South Korea) 地震中 67 栋受损建筑	48
[49]	多层感知器	8	三分类	2016 年厄瓜多尔(Ecuador) 地震中 171 栋受损建筑	64
			四分类	2015 年尼泊尔(Nepal) 地震中 135 栋受损建筑	60
[50]	随机森林	8	三分类	2015 年尼泊尔(Nepal) 地震 76. 2 万座受损建筑	64. 0
[10]	随机森林	6	五分类	2010 年克拉沃沃(Kraljevo) 地震 1 979 座受损建筑	85
本文研究	随机森林	16	四分类	1997—2014 年新西兰全国范围内 27 次地震中 142 543 受损建筑	75. 4

(1) 首次将时间跨度大、地震事件多、分布范围广、涉及维度多的详细实际震害数据进行整合,并应用于地震损失预测研究中,极大改善了当前机器学习模型应用于震害损失预测研究中泛化能力和精度受限的问题。

(2) 通过比较 6 种机器分类学习模型对于 4 类损伤标签的预测性能,得出随机森林模型在各项性能指标(精确率、召回率、 F_1 测试值和准确率)中均优于其他 5 种模型。

(3) 经过超参数优化、代价敏感学习后的随机森林模型的整体准确率最高可达 75.4%,对于 4 类标签的召回率可以分别达到 88.2%、55.0%、60.7%和 70.8%,表明该模型可以应用于建筑结构地震破坏预测。

(4) 随机森林模型经过迭代训练之后,模型的整体预测精度在仅考虑 12 个影响因素的情况下仍然能够达到 73.7%,一定程度上说明本文的模型有较好的适用性。

(5) 结果表明基于本文研究框架所训练的地震破坏预测模型具有良好的精度表现与适用性。未来中国灾害普查大数据库得以建立后,本文研究的震害大数据分析框架对中国未来机器学习应用于建筑群震损预测具有重要参考意义。

参 考 文 献

[1] Nex F, Duarte D, Tonolo F G, et al. Structural building damage detection with deep learning: assessment of a state-of-the-art CNN in operational conditions [J]. Remote Sensing, 2019, 11 (23): 2765.

[2] Khodaverdizahraee N, Rastiveis H, Jouybari A. Segment-by-seg-

ment comparison technique for earthquake-induced building damage map generation using satellite imagery [J]. International Journal of Disaster Risk Reduction, 2020, 46: 101505.

[3] 臧石磊,冯石,李玉森,等. 基于模糊综合评判法的辽宁省老旧砌体房屋震害预测 [J]. 地震研究, 2019, 42 (2): 166-171 305.

Zang Shilei, Feng Shi, Li Yusen, et al. Seismic damage prediction of old masonry buildings in Liaoning Province based on fuzzy comprehensive evaluation method [J]. Journal of Seismological Research, 2019, 42 (2): 166-171, 305.

[4] 张桂欣,孙柏涛. 基于模糊层次分析的建筑物单体震害预测方法研究 [J]. 工程力学, 2018, 35 (12): 185-193, 202.

Zhang Guixin, Sun Baitao. Study on seismic damage prediction method of single building based on fuzzy analytic hierarchy process [J]. Engineering Mechanics, 2018, 35 (12): 185-193, 202.

[5] 孙柏涛,李洋. 中国震害预测工作的沿革与发展 [J]. 工程力学, 2021, 38 (1): 1-7, 51.

Sun Baitao, Li Yang. Evolution and development of earthquake disaster prediction in China [J]. Engineering Mechanics, 2021, 38 (1): 1-7, 51.

[6] 孙柏涛,张桂欣,邓宏宇,等. 考虑设防水准的群体建筑物震害预测方法 [J]. 土木工程学报, 2013, 46 (5): 117-121.

Sun Baitao, Zhang Guixin, Deng Hongyu, et al. A method for earthquake damage prediction of building group considering seismic fortification level [J]. China Civil Engineering Journal, 2013, 46 (5): 117-121.

[7] 金赟赟,李杰. 基于易损性贝叶斯网络的群体建筑快速震害预测 [J]. 自然灾害学报, 2020, 29 (5): 64-72.

Jin Yunyun, Li Jie. Rapid earthquake damage prediction for group buildings based on vulnerability Bayesian network [J]. Journal of Natural Disasters, 2020, 29 (5): 64-72.

[8] 张令心,戴静涵,沈俊凯,等. 基于 LM-BP 神经网络的钢筋混凝土框架结构震害快速预测模型 [J]. 自然灾害学报, 2019, 28 (2): 1-9.

Zhang Lingxin, Dai Jinghan, Shen Junkai, et al. Rapid prediction

- model of earthquake damage to frame structure based on LM-BP neural network[J]. *Journal of Natural Disasters*, 2019, 28(2): 1-9.
- [9] Roeslin S, Ma Q, Juárez-García H, et al. A machine learning damage prediction model for the 2017 Puebla-Morelos, Mexico, earthquake[J]. *Earthquake Spectra*, 2020, 36(S): 314-339.
- [10] Stojadinovic Z, Kovačević M, Marinković D, et al. Rapid earthquake loss assessment based on machine learning and representative sampling[J]. *Earthquake Spectra*, 2022, 38(1): 152-177.
- [11] Mangalathu S, Sun H, Nweke C C, et al. Classifying earthquake damage to buildings using machine learning[J]. *Earthquake Spectra*, 2020, 36(1): 183-208.
- [12] Chen J, Tang H, Ge J, et al. Rapid assessment of building damage using multi-source data: a case study of April 2015 nepal earthquake[J]. *Remote Sensing*, 2022, 14(6): 1358.
- [13] Molas G L, Yamazaki F. Neural networks for quick earthquake damage estimation[J]. *Earthquake Engineering & Structural Dynamics*, 1995, 24(4): 505-516.
- [14] 王自法, Park S, Lee S, 等. 提高地震灾害损失估计精度的几点研究[J]. *地震工程与工程振动*, 2014, 34(4): 110-114.
Wang Zifa, Park S, Lee S, et al. Quantification improvement of earthquake loss estimation[J]. *Earthquake Engineering and Engineering Dynamics*, 2014, 34(4): 110-114.
- [15] Spence R J S, Coburn A W, Pomonis A, et al. Correlation of ground motion with building damage: the definition of a new damage-based seismic intensity scale[C]//Proceedings of the Tenth World Conference on Earthquake Engineering. Madrid: Crc Press, 1992: 551-556.
- [16] Whitman R V. Damage probability matrices for prototype buildings: R732-57[R]. Cambridge Massachusetts: Massachusetts Institute of Technology Department of Civil Engineering Research Report, 1973.
- [17] 刘渊, 王自法, 赵登科. 基于新西兰详细地震破坏数据的建筑物构件损失分析[J]. *地震工程与工程振动*, 2021, 41(5): 186-195.
Liu Yuan, Wang Zifa, Zhao Dengke. Building component level loss analysis based on detailed earthquake loss data in New Zealand[J]. *Earthquake Engineering and Engineering Dynamics*, 2021, 41(5): 186-195.
- [18] Rossetto T, Elnashai A. Derivation of vulnerability functions for European-type RC structures based on observational data[J]. *Engineering Structures*, Elsevier, 2003, 25(10): 1241-1263.
- [19] Lang K, Bachmann H. On the seismic vulnerability of existing buildings: a case study of the city of Basel[J]. *Earthquake Spectra*, 2004, 20(1): 43-66.
- [20] Giovenale P, Cornell C A, Esteva L. Comparing the adequacy of alternate ground motion intensity measures for the estimation of structural responses[J]. *Earthquake Engineering & Structural Dynamics*, 2004, 33(8): 951-979.
- [21] Zhao J X, Zhou S, Zhou J, et al. Ground-motion prediction equations for shallow crustal and upper-mantle earthquakes in Japan using site class and simple geometric attenuation functions[J]. *Bulletin of the Seismological Society of America*, 2016, 106(4): 1552-1569.
- [22] Zhao J X, Liang X, Jiang F, et al. Ground-motion prediction equations for subduction interface earthquakes in Japan using site class and simple geometric attenuation functions[J]. *Bulletin of the Seismological Society of America*, 2016, 106(4): 1518-1534.
- [23] Zhao J X, Jiang F, Shi P, et al. Ground-motion prediction equations for subduction slab earthquakes in Japan using site class and simple geometric attenuation functions[J]. *Bulletin of the Seismological Society of America*, 2016, 106(4): 1535-1551.
- [24] Wald D J, Allen T I. Topographic slope as a proxy for seismic site conditions and amplification[J]. *Bulletin of the Seismological Society of America*, 2007, 97(5): 1379-1395.
- [25] 赵登科, 王自法, 刘渊, 等. 基于新西兰实际震害资料的地震损失不确定性分析[J]. *地震工程与工程振动*, 2021, 41(2): 84-95.
Zhao Dengke, Wang Zifa, Liu Yuan, et al. Earthquake loss uncertainty based on detailed loss data in New Zealand[J]. *Earthquake Engineering and Engineering Dynamics*, 2021, 41(2): 84-95.
- [26] Dolce M, Kappos A, Masi A, et al. Vulnerability assessment and earthquake damage scenarios of the building stock of Potenza (Southern Italy) using Italian and Greek methodologies[J]. *Engineering Structures*, Elsevier, 2006, 28(3): 357-371.
- [27] Rogers N, Van Ballegooy S, Williams K, et al. Considering post-disaster damage to residential building construction is our modern building construction resilient[C]//Proc. 6th International Conference on Earthquake Geotechnical Engineering. Christchurch: ISSMGE Technical Committee, 2015: 1-4.
- [28] Rossi L, Stupazzini M, Parisi D, et al. Empirical fragility functions and loss curves for Italian business facilities based on the 2012 Emilia-Romagna earthquake official database[J]. *Bulletin of Earthquake Engineering*, 2020, 18(4): 1693-1721.
- [29] Council A T. Earthquake damage evaluation data for California[M]. Redwood: Applied Technology Council, 1985.
- [30] FEMA356 Prestandard and commentary for the seismic rehabilitation of buildings[S]. Washington DC: Federal Emergency Management Agency, 2000.
- [31] 曹振中, 侯龙清, 袁晓铭, 等. 汶川 8.0 级地震液化震害及特征[J]. *岩土力学*, 2010, 31(11): 3549-3555.
Cao Zhenzhong, Hou Longqing, Yuan Xiaoming, et al. Characteristics of liquefaction-induced damages during Wenchuan Ms8.0 earthquake[J]. *Rock and Soil Mechanics*, 2010, 31(11): 3549-3555.
- [32] 李兆焱, 袁晓铭. 2016 年台湾高雄地震场地效应及砂土液化破坏概述[J]. *地震工程与工程振动*, 2016, 36(3): 1-7.
Li Zhaoyan, Yuan Xiaoming. Seismic damage summarization of site effect and soil liquefaction in 2016 Kaohsiung earthquake[J]. *Earthquake Engineering and Engineering Dynamics*, 2016, 36(3): 1-7.
- [33] 张文彬, 汪云龙, 曹振中, 等. 2011 年东日本大地震人工填土地液化特征综述[J]. *世界地震工程*, 2017, 33(2): 13-23.
Zhang Wenbin, Wang Yunlong, Cao Zhenzhong, et al. Review of liquefaction characteristics in artificially filled land during the 2011 Great East Japan Earthquake[J]. *World Earthquake Engineering*, 2017, 33(2): 13-23.
- [34] Géron A. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: concepts, tools, and techniques to build intelligent systems[M]. Sebastopol: O'Reilly Media, Inc., 2019.
- [35] Akyol S, Gulbandilar E. Investigation of the relationships and effects of urban transformation parameters for risky structures: a rapid assess-

- ment model[J]. IEEE Access ,2019 ,7: 150983-150991.
- [36] Tesfamariam S ,Liu Z. Earthquake induced damage classification for reinforced concrete buildings[J]. Structural Safety ,2010 ,32 (2) : 154-164.
- [37] 詹森,张景发,龚丽霞,等. 基于纹理特征的高分辨率合成孔径雷达影像单体建筑物震害信息识别[J]. 科学技术与工程, 2019 ,19(31) : 47-54.
- Zhan Sen ,Zhang Jingfa ,Gong Lixia ,et al. Recognition of single building seismic damage information in high resolution synthetic aperture radar images based on texture features[J]. Science Technology and Engineering ,2019 ,19(31) : 47-54.
- [38] Oh B K ,Park Y ,Park H S. Seismic response prediction method for building structures using convolutional neural network [J]. Structural Control and Health Monitoring ,2020 ,27(5) : e2519
- [39] Slattery S. Hypertext classification [D]. Pittsburgh: Carnegie Mellon University ,2002.
- [40] 赵晓东,徐振涛,刘福,等. 基于极端梯度提升算法的滑坡易发性评价模型[J]. 科学技术与工程, 2022 ,22 (23) : 10347-10354.
- Zhao Xiaodong ,Xu Zhentao ,Liu Fu ,et al. Landslide susceptibility evaluation model based on XGBoost [J]. Science Technology and Engineering ,2022 ,22(23) : 10347-10354.
- [41] Lu X ,Zeng X ,Xu Z ,et al. Improving the accuracy of near real-time seismic loss estimation using post-earthquake remote sensing images[J]. Earthquake Spectra ,2018 ,34(3) : 1219-1245.
- [42] Lu X ,Xu Y ,Tian Y ,et al. A deep learning approach to rapid regional post-event seismic damage assessment using time-frequency distributions of ground motions [J]. Earthquake Engineering & Structural Dynamics ,2021 ,50(6) : 1612-1627.
- [43] Xu Y ,Lu X ,Cetiner B ,et al. Real-time regional seismic damage assessment framework based on long short-term memory neural network[J]. Computer-Aided Civil and Infrastructure Engineering ,2021 ,36(4) : 504-521.
- [44] Kourehpaz P ,Molina Hutt C. Machine learning for enhanced regional seismic risk assessments[J]. Journal of Structural Engineering ,2022 ,148(9) : 04022126.
- [45] Won J ,Shin J. Machine learning-based approach for seismic damage prediction method of building structures considering soil-structure interaction[J]. Sustainability ,2021 ,13(8) : 1-14.
- [46] Harirchian E ,Lahmer T ,Rasulzade S. Earthquake hazard safety assessment of existing buildings using optimized multi-layer perceptron neural network[J]. Energies ,2020 ,13(8) : 1-16.
- [47] Harirchian E ,Lahmer T ,Kumari V ,et al. Application of support vector machine modeling for the rapid seismic hazard safety evaluation of existing buildings[J]. Energies ,2020 ,13(13) : 1-15.
- [48] Harirchian E ,Kumari V ,Jadhav K ,et al. A machine learning framework for assessing seismic hazard safety of reinforced concrete buildings[J]. Applied Sciences ,2020 ,10(20) . DOI: 10.3390/app/0207153.
- [49] Harirchian E ,Jadhav K ,Kumari V ,et al. ML-EHSAPP: a prototype for machine learning-based earthquake hazard safety assessment of structures by using a smartphone app[J]. European Journal of Environmental and Civil Engineering ,2022 ,26 (11) : 5279-5299.
- [50] Ghimire S ,Guéguen P ,Giffard-Roisin S ,et al. Testing machine learning models for seismic damage prediction at a regional scale using building-damage dataset compiled after the 2015 Gorkha Nepal earthquake[J]. Earthquake Spectra ,2022 ,38(4) : 2970-2993.